

텍스트라는 원석에서 질서를 조각하다

- 자연어 처리(NLP)를 위한 텍스트 데이터 정제와 정규화의 예술
- 날것의 데이터에서 기계가 이해할 수 있는 완벽한 형태를 끌어내는 과정

	자	돔	절	벽	함	언	과
	세	로	만	압	이	마	라
텍	스	트	는	다	연	잘	서
게	안	이	름	피	업	는	데
기	능	어	터	장	도	겨	동
제	혁	에	들	마	링	크	니
칙	도	리	마	뷰	이	제	외
세	계	항	만	대	거	산	한
리	종	사	다	그	록	엔	너
인	수	로	속	결	제	해	낭
슴	트	케	패	제	크	리	노

기계에게 날것의 텍스트는 혼돈 그 자체입니다

- 토큰화(Tokenization) 전후로 반드시 거쳐야 하는 두 가지 필수 기초 공사

- 정제 (Cleaning)

- 코퍼스(Corpus)에서 기계의 학습을 방해하는 무의미한 노이즈 데이터를 덜어내는 작업
- 완벽한 토큰화를 위한 사전/사후 필수 과정

- 정규화 (Normalization)

- 표현 방식이 다른 단어들을 하나의 통일된 형태로 병합하는 작업
- 데이터의 복잡도를 낮추고 기계의 이해도를 극대화하는 핵심 단계



서로 다른 표기, 하나의 의미

- 의미가 같지만 표기가 다른 단어들을 단일 형태로 통합 (규칙 기반 정규화)
- 분산된 단어의 빈도수를 하나로 모아 모델의 학습 효율성 증대
- 대표적인 통합 사례:
 - USA와 US는 동일한 국가를 지칭하므로 US로 병합
 - uh-huh와 uhhuh처럼 형태만 다른 감탄사를 uhhuh로 병합
- 하나의 키워드 검색만으로 모든 변형된 표현을 동시에 포착 가능



대소문자 통합이 가져오는 극적인 효율성

- 대부분의 텍스트는 소문자로 작성됨을 활용한 데이터 규격화
- 모든 문자를 소문자로 변환하여 전체 단어 사전(Vocabulary)의 크기를 획기적으로 축소
- 검색 엔진의 마법 (효율성 극대화):
 - 사용자가 ferrari를 검색할 때 발생하는 극적인 매칭 효과
 - 원본 데이터가 문장 첫 단어인 Automobile이거나 고유명사 Ferrari이더라도 완벽하게 탐색 가능
 - 대소문자 차이로 인한 정보 누락 방지



무작정 소문자로 통합할 때 발생하는 치명적인 예외

- 모든 단어를 일괄 소문자로 변환하는 규칙의 명백한 한계
- 대소문자 구분이 단어의 본질적 의미를 결정하는 결정적 순간들
- 치명적인 의미 변질의 예시:
 - US (미국) vs us (우리) : 대문자가 사라지면 국가가 대명사로 전락
 - Bush (사람 이름) vs bush (덤불) : 고유명사가 고유명사의 식별력 상실
 - General Motors (회사 이름) : 기업명이 일반 명사로 대체됨
- 머신러닝 시퀀스 모델을 통한 선별적 대문자 보존 방식이 대안으로 존재

US



(미국)


us



(우리)

덜어냄의 미학: 등장 빈도가 적은 단어

- 자연어 처리에 전혀 도움이 되지 않는 파편(노이즈)의 과감한 제거
- 통계적 유의미성이 없는 데이터를 잘라내어 연산 효율 확보
- 스팸 메일 분류기 설계의 딜레마:
 - 총 100,000통의 메일 데이터 확보
 - 그중 단 5번만 등장하는 단어의 가치는?
 - 정상 메일과 스팸을 구분하는 기준점 (Feature)으로서의 역할 수행 불가
- 빈도가 극도로 낮은 단어는 기계 학습의 방해물일 뿐이므로 즉시 덜어냄



짧은 단어 지우기: 영어권의 훌륭한 노이즈 필터

- 영어권 언어의 고유한 특성을 활용한 초고속 정제 기법
- 길이가 짧은 단어를 삭제하는 것만으로 무의미한 불용어와 구두점 동시 제거
- 길이 제한에 따른 필터링 효과:
 - 길이 1 제거: 관사 a, 주어 I 등 소거
 - 길이 2 제거: it, at, to, on, in, by 등 핵심 불용어 완벽 소거
- 주의사항: 길이 3인 단어부터는 fox, dog, car 등 핵심 명사가 포함되므로 데이터 특성에 따른 신중한 접근 필수

I was wondering if anyone out there
could enlighten me on this car.

이 완벽해 보이는 규칙을 한국어에 똑같이 적용해도 될까요?

- 영어 코퍼스에서 검증된 강력한 1~2글자 제거 필터
- 과연 이 필터가 아시아권 언어, 특히 한국어에서도
동일한 위력을 발휘할 것인가?
- 언어의 근본적인 뼈대를 묻는 구조적 질문

언어의 구조적 차이: 글자가 품은 정보의 무게

- 영어와 한국어는 단 한 글자가 지니는 ‘의미의 밀도’가 전혀 다름
- 단어 길이의 통계적 차이:
 - 영어 단어 평균 길이: 6~7자
 - 한국어 단어 평균 길이: 2~3자
- 한국어의 짙은 함축성:
 - 한자어 기반의 구조로 단 한 글자만으로도 완결된 의미를 가지는 경우가 대다수
 - 글자 하나하나가 독립적인 정보의 덩어리로 기능함



하나의 의미를 표현하기 위해 필요한 글자의 수

- 동일한 대상을 지칭할 때 발생하는 절대적인 글자 수의 격차
- 영어의 짧은 단어 제거 규칙(길이 1~2 제한)을 한국어에 적용할 경우 문장의 핵심 의미가 완벽하게 파괴됨
- 극명한 밀도의 차이:
 - s-c-h-o-o-l (6글자) = 학-교 (2글자)
 - d-r-a-g-o-n (6글자) = 용 (1글자)
- 한국어 자연어 처리에서는 단순한 '길이 기반 제거'가 아닌 '형태소 분석' 기반의 정밀한 접근이 요구됨



장인의 정밀한 조각칼: 정규 표현식 (Regular Expression)

- 언어의 특성까지 파악한 장인에게 주어지는 가장 강력한 수술용 메스
- 코퍼스 내에 반복적이고 규칙적으로 등장하는 특정 패턴의 노이즈를 일망타진
- 정규 표현식의 주요 타겟 노이즈:
 - 웹 크롤링 데이터: 무수히 산재한 HTML 문서의 태그들 (<div>, <a> 등)
 - 뉴스 기사 코퍼스: 본문과 무관한 게재 시간 로그 및 기자 이메일 주소
- 규칙의 패턴만 잡아낸다면 텍스트의 손상 없이 불순물만 완벽하게 도려낼 수 있음



정규 표현식을 활용한 노이즈 제거의 실제

- 파이썬의 re 모듈을 활용하여 1~2글자의 짧은 영어 단어를 한 번에 제거하는 정규 표현식 구현

```
import re

text = 'I was wondering if anyone out there could enlighten me on this car.'


# 길이가 1~2인 단어들을 정규 표현식을 이용하여 삭제
shortword = re.compile(r'\W*\b\w{1,2}\b')

print(shortword.sub('', text))
```

- 정제 결과:
 - was wondering anyone out there could enlighten this car. (의미를 가진 핵심 단어만 보존됨)

완벽한 정제란 존재하지 않습니다

- 모든 예외를 처리하고 불순물을 0%로 만드는 완벽한 전처리는 불가능의 영역
- 대소문자 예외 처리(US vs us)를 위해 복잡한 머신러닝 모델을 도입할 수 있음
- 그러나 훈련 코퍼스 자체에 이미 사용자의 오타나 규칙 파괴가 만연하다면 고도화된 모델조차 무용지물
- 현실적인 장인의 타협점:
 - 때로는 수많은 예외 처리를 포기하고 '전체 소문자 일괄 변환'을 선택하는 것이 실용적인 합의점이 됨
 - '이 정도면 모델 학습에 충분하다'는 직관과 통계적 타당성이 중요



데이터의 맥락을 읽는 자가 의미를 지배한다

- 텍스트 데이터의 정제와 정규화는 단순히 기계적으로 코드를 실행하는 과정이 아님
- 조각을 완성하는 세 가지 통찰:
 1. 데이터가 생성된 도메인의 특성을 파악할 것 (스팸 메일인가, 뉴스 기사인가?)
 2. 다루고자 하는 언어의 본질적 밀도와 구조를 이해할 것 (영어의 길이 제한 vs 한국어의 형태소)
 3. 완벽주의를 버리고 기계의 학습 목적에 부합하는 합의점을 찾을 것
- 혼돈(Noise) 속에서 기계가 읽어낼 수 있는 '진짜 의미(Signal)'의 형태를 빚어내는 가장 경이로운 첫걸음

